



交通运输系统工程与信息

Journal of Transportation Systems Engineering and Information Technology

ISSN 1009-6744, CN 11-4520/U

《交通运输系统工程与信息》网络首发论文

题目：基于地理自编码与跨域迁移的公交出行需求分层聚类方法
作者：田君豪，邢璐，廖世豪，桂瑰，蒋小晴
收稿日期：2026-01-22
网络首发日期：2026-04-28
引用格式：田君豪，邢璐，廖世豪，桂瑰，蒋小晴. 基于地理自编码与跨域迁移的公交出行需求分层聚类方法[J/OL]. 交通运输系统工程与信息.
<https://link.cnki.net/urlid/11.4520.u.20260427.1439.004>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

基于地理自编码与跨域迁移的公交出行需求分层聚类方法

田君豪¹, 邢璐¹, 廖世豪¹, 桂瑰^{*1}, 蒋小晴²

(1. 中南大学, 自动化学院, 长沙 410083; 2. 湖南中车智行科技有限公司, 长沙 410017)

摘要: 为提升城市公交出行需求聚类的精确性, 突破传统聚类方法在非凸形态捕捉、噪声适应性和参数依赖性等方面的局限, 提出一种支持跨域应用的公交出行需求聚类通用框架, 并据此设计一种基于地理自编码器的分层聚类算法(Geographic AutoEncoder based Hierarchical Clustering, GeoAE-HC)。首先引入正余弦位置编码并设计地理自注意力机制以捕捉公交出行需求数据间的特征相似性与地理邻近性; 然后设计融合密度聚类与均值聚类的分层聚类方法并应用在自编码器提取的潜在特征空间中, 实现对公交出行需求分布的准确聚类; 最后为提升模型在不同城市的跨域泛化能力, 设计结合域对抗训练和冻结编码器微调解码器的迁移学习策略, 以剥离城市特异性噪声。仿真结果表明, 在成都数据集上当聚类中心数为 375 时, GeoAE-HC 算法的各项评价指标均优于对比算法, 其中轮廓系数较深度嵌入聚类(Deep Embedded Clustering, DEC)、DK-means 与 K-means 分别提升 11.82%、23.14%和 45.01%, Calinski-Harabasz (CH) 指数较 DEC、DK-means 与 K-means 分别提升 6.14%、5.62%和 14.44%。在跨域迁移至北京数据集后 GeoAE-HC 算法性能表现也优于对比算法, 验证了该算法的有效性和泛化能力。

关键词: 智能交通; 深度聚类; 自编码器; 公交出行需求; 迁移学习

中图分类号: U491.2

文献标志码: A

A Hierarchical Clustering Method for Public Transit Demand Based on Geographic Autoencoder and Cross-Domain Transfer

TIAN Junhao¹, XING Lu¹, LIAO Shihao¹, GUI Gui^{1*}, JIANG Xiaoqing²

(1. School of Automation, Central South University, Changsha 410083, China;

2. Hunan CRRC Intelligent Transport Technology Co., Ltd, Changsha 410017, China)

Abstract: To enhance the accuracy of urban public transit travel demand clustering and overcome the limitations of traditional clustering methods in capturing non-convex patterns, handling noise, and reducing parameter dependency, a general framework for public transit travel demand clustering supporting cross-domain applications is proposed. Based on this, a Geographic AutoEncoder based Hierarchical Clustering (GeoAE-HC) algorithm is designed. First, sine-cosine positional encoding is introduced and a geographical self-attention mechanism is designed to capture both feature similarity and geographical proximity among transit travel demand data. Then, a hierarchical clustering method integrating density-based clustering and mean-based clustering is developed and applied in the latent feature space extracted by the autoencoder, enabling accurate clustering of travel demand distribution. Finally, to improve the cross-domain generalization ability of the model across different cities, a transfer learning strategy combining domain adversarial training with a frozen encoder and fine-tuned decoder is

收稿日期: 2026-01-22

修回日期: 2026-03-25

录用日期: 2026-04-17

基金项目: 国家自然科学基金/National Natural Science Foundation of China (62473381), 湖南省重点研发计划/Hunan Provincial Key Research and Development Program (2025JK2068)

作者简介: 田君豪 (1997-), 男, 江西上饶人, 博士生。 *通信作者: guigui@csu.edu.cn

引用格式: 田君豪, 邢璐, 廖世豪, 等. 基于地理自编码与跨域迁移的公交出行需求分层聚类方法[J]. 交通运输系统工程与信息, 2026, 26(3). [TIAN J H, XING L, LIAO S H, et al. A Hierarchical Clustering Method for Public Transit Demand Based on Geographic Autoencoder and Cross-Domain Transfer[J]. Journal of Transportation Systems Engineering and Information Technology, 2026, 26(3).]

designed to strip away city-specific noise. Simulation results show that on the Chengdu dataset with 375 cluster centers, all evaluation metrics of the GeoAE-HC algorithm are superior to those of the comparison algorithms. Specifically, the Silhouette Coefficient is improved by 11.82%, 23.14%, and 45.01% compared to Deep Embedded Clustering (DEC), DK-means, and K-means, respectively, and the Calinski-Harabasz (CH) Index is improved by 6.14%, 5.62%, and 14.44%, respectively. After cross-domain transfer to the Beijing dataset, the performance of GeoAE-HC also outperforms those of comparative algorithms, validating its effectiveness and generalization capability.

Keywords: intelligent transportation; deep clustering; autoencoder; public transit demand; transfer learning

0 引言

随着我国居民出行需求和出行选择的多元化,传统公交行业普遍面临客流分布不均、运营效率待提升等现实挑战^[1]。利用聚类算法对公交出行需求进行聚合分析,可将离散的需求点按照空间邻近关系与分布密度划分为不同的簇,并通过识别各簇的中心位置与边界范围,揭示出行需求在城市空间中的集聚特征。以此为参考设置的公交站点,往往能够有效覆盖客流密集区域、服务高需求人群,从而实现公交站点布局与出行需求空间结构的精准匹配,对于提升公共交通系统的供需匹配度与运行服务效能具有重要理论意义与实践价值。

针对出行需求聚类问题,国内外专家学者已开展许多相关研究。Shu 等^[2]采用 K-means 算法对乘客出行需求进行聚类,用于确定定制公交的停靠站点,但 K-means 算法存在噪声适应性差的问题。为此 Hamann 等^[3]设计了一种两阶段聚类算法,先采用 K-means 算法进行初步聚类,再用 K-Prototypes 算法对异质性较高的簇进行二次聚类。但 K-means 算法对初始聚类中心敏感,聚类质量并不稳定。因此, Wu 等^[4]先采用 K-means++ 算法对出行需求点的经纬度坐标数据进行初始聚类,再利用拟牛顿法对聚类结果进行微调和优化。然而城市出行高密度区域在地理空间上往往呈现非规整的几何形态,可能沿主要交通干道呈线性或带状分布,或围绕大型枢纽站形成不规则的多边形区域,而 K-means 及其改进算法是基于欧氏距离最小化方差原则设计的,倾向于生成球状或凸状的簇,在捕捉非凸空间形态方面能力有所欠缺,导致其在对大规模城市公交出行需求数据进行聚类时表现不佳^[5]。

相较于 K-means 算法, DBSCAN(Density-Based Spatial Clustering of Applications with Noise) 算法的优势在于其能够识别任意形状簇^[6]。因此 Saputra 等^[7]利用 DBSCAN 算法从大量网约车轨迹数据中识别出高频上下车热点区域,以优化接送路线、提升接单效率。然而 DBSCAN 算法可能将空间邻近的高密度点集聚合为一个大型簇,难以进一步解析其内部的结构。为此,陈君等^[8]提出一种 DK-means 方法,在 DBSCAN 算法识别出的核心点簇上利用 K-means 算法进行二次划分。但 DBSCAN 算法使用欧氏距离进行密度聚类,忽略了实际道路的拓扑结构,导致聚类结果中可能包含实际不可达区域。因此 Xing 等^[9]将图论算法融入到 DBSCAN 的邻域搜索过程中,以获得输出更符合实际路网结构的出行区域划分结果。由于 DBSCAN 算法对于邻域半径和最小邻居数这两个关键参数具有高敏感性, Hou 等^[10]通过主导集聚类自动生成初始簇,并依据各初始簇内部数据点的距离分布自适应地确定 DBSCAN 算法中每个簇的邻域半径参数,从而实现关键参数的自适应调节。自适应参数策略虽为在中小规模、密度均匀的数据集上应对参数敏感性提供了解决方案,但对参数全局一致性的依赖,制约了其在大规模、高维数据集下的适用性^[11]。可见,上述公交出行需求聚类策略仍面临处理大规模高维复杂数据能力不足的问题,设计能够自主学习高维数据底层特征、并适应复杂分布的智能聚类方法,成为关键研究方向。

为克服上述问题,有部分学者采用深度聚类策略,利用深度神经网络自主学习高维数据的底层特征表达,再在学习到的特征空间中进行聚类。Li 等^[12]将堆叠自编码器与 K-means 算法进行结合,利用堆叠自编码器对地铁刷卡数据进行特征降维,进而通过聚类算法从中识别乘客的通勤

模式，但其自编码器损失函数仅关注重构误差，导致潜空间对站点地理邻接不敏感。Olive 等^[13]在自编码器损失函数中加入簇分配约束，使潜空间在训练阶段即考虑簇紧凑性，但其约束权重全局固定，仍可能导致“空间分割”问题，即特征相似但地理空间相距甚远的需求点，因在特征空间中映射位置相近而被错误地划分到同一类中。由此获得的聚类结果虽然在特征空间中是“正确”的，但在地理空间上却是无意义的。为此，Saronian 等^[14]提出一种基于联合优化重构损失与聚类损失的深度连续聚类框架，使自编码器在特征提取过程中同步考虑样本间的局部相似性，有效缓解空间分割问题。但该方法的性能评估集中于单一数据集，其不同城市、不同交通结构下的泛化能力未得到充分验证。

综上所述，为弥补现有方法在捕捉非凸形态、克服参数敏感性、缓解空间分割与实现跨域泛化等方面的不足，本文提出一种出行需求聚类通用框架，并基于该框架设计了一种基于地理自编码器的分层聚类算法(Geographic AutoEncoder based Hierarchical Clustering, GeoAE-HC)，用于揭示乘客出行需求的地理分布特性，主要贡献包含以下三方面：

(1) 构建可支持跨域应用的公交出行需求聚类框架：通过编码器提取具有空间判别性的特征，并设计聚类算法应用于提取出的潜在特征空间当中，最后基于迁移学习策略提升所设计框架用于不同城市时的泛化能力。

(2) 提出一种改进的地理增强型自编码器，通过嵌入正弦位置编码与距离感知自注意力机制，强化模型对出行需求数据空间绝对位置与相对关联的建模能力，并引入梯度反转对抗训练，有效剥离区域特异性噪声，提升所提取特征的域不变性。

(3) 设计基于域对抗训练和冻结编码器微调解码器的迁移学习策略，使编码器具备跨城市快速适配应用的特征提取能力，并在成都与北京的公交出行需求数据集上完成了从源域到目标域的跨域迁移性能验证。

1 框架设计与算法结构

本文提出一种支持跨域应用的公交出行需求聚类通用框架，该框架由地理空间特征提取、需求特征聚类与跨域迁移学习 3 部分组成，基于该框架，设计了一种 GeoAE-HC 算法，该算法的结构示意图如图 1 所示。




图 1 GeoAE-HC 算法结构示意图

Fig. 1 Structure diagram of the GeoAE-HC algorithm

各部分的设计思路与逻辑关系如下所示：

(1) 地理空间特征提取：为从原始数据中获取具有空间语义的潜在特征表示并避免空间割裂现象，本文构建了一种地理自编码器。相较于传统自编码器，该模型通过引入位置编码增强对地理位置分布的理解能力，并结合地理感知自注意力机制，使所提取的特征能够更准确地刻画数据间的空间邻近关系。

(2) 需求聚类设计：由于高密度出行区域的分布常呈现出非凸形态，其内部结构往往复杂并且还存在噪声干扰的问题，为此本文设计分层聚类算法，首先采用密度聚类算法识别聚集区域，区分噪声点，以捕捉任意形状的簇；随后根据簇的规模进行自适应判别，对于规模较大的簇进行二次分解，以解析大型枢纽或连续片区等高密度出行区域内部可能存在的子结构。

(3) 跨域迁移学习：针对自编码器在跨城市应用场景下泛化能力不足的问题，引入迁移学习策略。通过域对抗训练使编码器学习到对域变化不敏感的表达，并在跨域迁移时冻结编码器以保持其特征提取和表征能力，仅对解码器进行微调训练，使编码器能够快速适应目标城市的数据分布特性，并以较低成本实现跨城市适配。

2 地理空间特征提取

2.1 特征扩展

为增强模型对出行需求空间分布情况的感知能力，需对原始数据进行多维度特征扩展。首先基于原始经纬度坐标构造四类地理空间语义特征：①局部密度指数，用于刻画各出行点周围的需求聚集程度；②距离中心区的反距离加权指数，反映样本点与城市核心区域的相对位置关系；③空间异质性指数，描述局部范围内需求分布的离散程度；④方位分布集中度，量化邻近点方向的一致性，进而识别沿道路的线性分布或枢纽的放射状分布等典型空间模式。随后，为消除城市间尺度差异及不同特征量纲的影响，将包括原始经纬度特征和扩展特征在内的 6 维特征分别进行最小-最大归一化，映射至 $[0, 1]$ 区间。

2.2 地理空间自编码

将传统自编码器直接输入经纬度坐标时，其全连接层会将坐标视为无序的数值特征，难以有效捕获和保持地理空间数据所固有的绝对位置语义与相对拓扑关系，这常导致聚类结果出现地理空间上的割裂或误合并。为此，本文构建了一种地理空间自编码器，编码器包含两个全连接层，通过 ReLU 激活函数逐步提取抽象特征，解码器则保持对称结构，负责从包含空间信息的潜在表示中重建输入的特征表述。为赋予模型空间认知能力，设计位置编码模块，采用正弦余弦函数为每一个经纬度坐标生成一个独特的位置嵌入向量，该编码将连续的标量坐标转换为一个周期性的向量表示，使模型能够区分不同位置并感知其相对顺序，编码公式如下：

$$\begin{cases} PE_{(pos, 2i)} = \sin\left(\frac{pos}{10000^{2i/d}}\right) \\ PE_{(pos, 2i+1)} = \cos\left(\frac{pos}{10000^{2i/d}}\right) \end{cases} \quad (1)$$

式中， PE 为位置编码向量； d 为潜在特征的预设维度； i 为维度索引； pos 为经纬度的标量；频率项 $10000^{2i/d}$ 构成了一个几何级数，使不同维度编码的波长范围处于 2π 到 $2\pi \times 10000$ 范围内，从而让模型能够同时捕获从很近到很远的空间关系。将位置编码向量 PE 与编码器初步提取的特征进行元素加和，作为后续地理感知注意力模块的输入。

2.3 地理感知注意力机制

输入的特征序列由样本点及其空间上最近的 k 个样本点共同构成， k 为近邻点数，决定了模型在特征提取时能够感知的局部空间范围。标准的自注意力机制针对该序列进行处理时，通过线性变换得到查询矩阵 $\mathbf{Q}$ 、键矩阵 $\mathbf{K}$ 和值矩阵 $\mathbf{V}$ 。注意力权重矩阵 $\mathbf{A}$ 的计算过程如式(2)所示：

$$\mathbf{A} = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d_k}}\right) \quad (2)$$

式中, $\sqrt{d_k}$ 为缩放因子, 用于稳定梯度。最终输出为加权求和形式, 即:

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \mathbf{AV} \quad (3)$$

该机制基于特征语义的相似性 (即 $\mathbf{QK}^T$) 分配注意力, 但忽略了数据点间的空间关系。对于地理坐标数据, 这可能造成两个特征相似但地理距离遥远的数据点被错误地赋予过高注意力权重, 而地理上邻近、本应属同一功能区域的点却可能关联不足。这种“特征相似性”与“空间邻近性”的割裂, 会导致聚类结果在地理空间上失去意义。

为解决该问题, 本文设计了一种地理感知注意力机制, 在注意力分数计算中, 显式地引入一个由地理距离决定的衰减权重项, 从而引导模型在关注特征相似性的同时, 优先聚合空间上邻近的信息。改进后的注意力权重矩阵 $\mathbf{B}$ 的计算过程如式(4)所示:

$$\mathbf{B} = \text{softmax} \left(\frac{\mathbf{QK}^T}{\sqrt{d_k}} + \gamma \cdot \Phi \right) \quad (4)$$

式中, γ 为平衡系数; Φ 为地理距离权重矩阵。为了将距离关系映射为随距离增加而衰减的权重, 采用如下负指数函数:

$$\Phi_{ij} = \exp(-\beta \cdot l_{ij}) \quad (5)$$

式中, β 为可学习参数; l_{ij} 表示点 i 与点 j 之间的空间距离, 当 D_{ij} 越小时, Φ_{ij} 越大。最终, 地理感知注意力模块的输出如下式所示:

$$\text{GeoAttention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \mathbf{BV} \quad (6)$$

此时, 注意力权重能够同时反映特征相似性与空间邻近性。该模块被集成于编码器网络中, 对位置编码增强后的特征进行处理, 模型生成的特征表示可为后续的聚类算法提供能够反映地理空间分布规律的高质量输入。

3 出行需求分层聚类

3.1 基于 DBSCAN 的宏观密度聚类

考虑到 DBSCAN 算法可以不预设簇的数量与形状, 而是依据数据的自然分布密度进行聚类, 适用于识别特征空间中任意形态的密集区域并有效区分噪声点。因此首先在自编码器生成的特征空间内, 采用分块处理的 DBSCAN 算法进行宏观密度聚类。

假设给定特征空间数据集 $M = \{\mathbf{z}_i\}_{i=1}^N$, 其中 $\mathbf{z}_i \in \mathbb{R}^d$ 表示第 i 个样本的特征向量。算法依赖于两个关键参数: 邻域半径 ε 和最小样本数 n 。对于任意一个样本点 $p \in M$, 其 ε -邻域定义为与 p 的距离不超过 ε 的所有样本点的集合, 即

$$N_\varepsilon(p) = \{q \in M | \text{dist}(p, q) \leq \varepsilon\} \quad (7)$$

式中, $\text{dist}(p, q)$ 表示样本 p 和 q 两点之间的欧氏距离度量。若样本点 p 的 ε -邻域内至少包含 n 个样本点, 则称 p 为核心点。若一个样本点 q 位于某个核心点 p 的 ε -邻域内, 则称 q 从 p 直接密度可达, 密度可达关系可通过一系列直接密度可达的点链传递。所有彼此密度可达的样本点将归于同一个簇, 不满足任何核心点密度可达条件的样本点则被标记为噪声点。

3.2 基于 MiniBatch K-means 的自适应细分聚类

经过 DBSCAN 算法对出行需求数据进行初步聚类后, 特征空间内的各个簇在规模和结构上已呈现出一定的差异。为进一步解析各个大规模簇的内部结构, 本文引入 MiniBatch K-means 算法进行自适应细分。

假设 DBSCAN 算法划分的第 j 个簇为 C_j , 该簇的样本数量记为 n_j 。设置阈值 T 作为判断是

否需要对簇进行细分的依据。对于样本数量 $n_j < T$ 的小规模簇，考虑到这类簇的地理范围有限并且其内部结构可能相对简单，因此将该类簇的所有样本数据地理坐标的算术均值作为聚类中心 μ_j ，计算公式如式(8)所示：

$$\mu_j = \frac{1}{n_j} \sum_{x_i \in C_j} x_i \quad (8)$$

式中， x_i 为第 i 个样本的经纬度坐标。对于样本数量 $n_j \geq T$ 的簇，若仍将簇内所有样本地理坐标的算术均值作为聚类中心，可能会掩盖其内部复杂的结构，因此对于这类簇需进行二次划分。二次划分是为了能够找到 k_j 个子簇 $\{S_{j1}, \dots, S_{jk_j}\}$ 及其对应的质心 $\{\mu_{j1}, \dots, \mu_{jk_j}\}$ ，以最小化簇内各个样本到该簇质心的平方误差和：

$$\min_{\{S_{j1}, \dots, S_{jk_j}\}} \sum_{t=1}^{k_j} \sum_{x_i \in S_{jt}} \|x_i - \mu_{jt}\|^2 \quad (9)$$

针对公交出行需求数据量庞大，计算效率受限的问题，采用 MiniBatch K-means 算法进行细分聚类。与传统 K-means 算法不同，MiniBatch K-means 算法在每次更新质心的过程中并不会使用全部数据，而是每次随机抽取一部分样本来更新。其质心的更新规则如式(10)所示：

$$\mu^{(new)} = \mu^{(old)} + \eta_t (x_i - \mu^{(old)}) \quad (10)$$

式中， η_t 表示在第 t 次迭代时衰减的学习率。这种质心的更新方式有助于在处理大规模数据时降低单次迭代的计算成本。

最终，分层聚类模块输出的所有候选中心点的集合 C_{final} 如式(11)所示：

$$C_{final} = \{\mu_j | n_j < T\} \cup \{\mu_{jt} | n_j \geq T, t=1, \dots, k_j\} \quad (11)$$

4 面向异质城市的跨域迁移学习

4.1 域对抗训练策略

由于不同城市的地理结构不同，出行需求的分布也存在差异，这种差异可能导致自编码器模型在源域上具有出色性能，但是在目标域上却出现性能退化的问题。为此，本文采用域对抗训练策略，使域判别器与特征编码器进行极大极小博弈，以此来获得域不变的特征表示。

若源域样本为 $x^s \sim P_s$ ，目标域样本为 $x^t \sim P_t$ 。编码器 $E(\cdot; \theta_e)$ 将输入特征映射为潜在特征 $z = E(x; \theta_e)$ ；解码器 $G(\cdot; \theta_g)$ 的作用则是从潜在特征空间中重构出输入特征；域判别器 $D(\cdot; \theta_d)$ 是二元分类器，作用在于判断出特征 z 的来源域。域分类损失 $\mathcal{L}_{domain}$ 的定义如式(12)所示：

$$\mathcal{L}_{domain}(\theta_e, \theta_d) = -\mathbb{E}_{x^s \sim P_s} [\log D(E(x^s; \theta_e); \theta_d)] - \mathbb{E}_{x^t \sim P_t} [\log(1 - D(E(x^t; \theta_e); \theta_d))] \quad (12)$$

式中， $\mathbb{E}$ 表示数学期望；在训练过程中，域判别器 D 通过最小化 $\mathcal{L}_{domain}$ 来更新其参数 θ_d 。而编码器 E 的参数 θ_e 需要通过最小化重构损失 $\mathcal{L}_{recon}$ 与最大化域判别器的损失 $\mathcal{L}_{domain}$ ，来生成让域判别器无法分辨来源的特征，从而使所提取到的特征不断向域不变的方向演化。此处所提到的重构损失 $\mathcal{L}_{recon}$ 与图 1 中的预测损失是一致的，计算公式如式(13)：

$$\mathcal{L}_{recon} = \frac{1}{N} \sum_{i=1}^N \|x_i - G(E(x_i; \theta_e); \theta_g)\|^2 \quad (13)$$

式中， x_i 表示第 i 个出行需求样本的特征向量， N 为样本数量。为最大化 $\mathcal{L}_{domain}$ ，在反向传播过程中引入梯度反转，将 $\mathcal{L}_{domain}$ 的梯度乘上一个负系数 $-\lambda$ 后再传递给编码器。因此，编码器参数 θ_e

的梯度实际由两部分构成：

$$\nabla_{\theta_e} \mathcal{L}_{total} = \nabla_{\theta_e} \mathcal{L}_{recon} - \lambda \cdot (\nabla_{\theta_e} \mathcal{L}_{domain}) \quad (14)$$

式中， λ 为对抗强度系数。为了确保训练过程的稳定性，将 λ 设置为从 0 开始逐渐增长， λ 的计算方式定义如式(15)所示：

$$\lambda = \min(\lambda_{max}, \frac{2 \cdot epoch}{total\ pochs} \cdot \lambda_{max}) \quad (15)$$

式中， $epoch$ 为当前训练轮次； $total\ pochs$ 为总训练轮次； λ_{max} 为预设的最大对抗强度。

此外，为进一步实现源域与目标域的潜在特征对齐，引入最大均值差异（Maximum Mean Discrepancy, MMD）作为正则项：

$$\mathcal{L}_{mmd} = \left\| \frac{1}{N_s} \sum_{i=1}^{N_s} \phi(z_i^s) - \frac{1}{N_t} \sum_{j=1}^{N_t} \phi(z_j^t) \right\|_{\mathcal{H}}^2 \quad (16)$$

式中， N_s 和 N_t 分别为源域和目标域的样本数量； $z_i^s = E(x_i^s; \theta_e)$ 和 $z_j^t = E(x_j^t; \theta_e)$ 分别为源域和目标域样本的潜在特征； $\phi(\cdot)$ 为核函数映射； $\|\cdot\|_{\mathcal{H}}$ 表示在再生核希尔伯特空间中的范数。

最终，编码器的整体优化目标如式(17)所示：

$$\min_{\theta_e} (\mathcal{L}_{recon} + \alpha \cdot \mathcal{L}_{mmd} - \lambda \cdot \mathcal{L}_{domain}) \quad (17)$$

式中， α 为 MMD 损失权重系数。通过对抗训练机制，编码器可提取到具有域不变性的特征表示。

4.2 基于冻结编码器与微调解码器的迁移方法

对编码器进行域对抗训练之后，为使其能够快速适应新的目标城市，采用“冻结编码器，微调解码器”的迁移策略。将已在编码器的参数 θ_e 完全冻结，使其在针对目标域的数据进行前向传播的过程中，作为固定的特征提取器使用，从而稳定地输出域不变特征。随后，仅对解码器 $G(\cdot; \theta_g)$ 的参数 θ_g 进行微调，目标是最小化其在目标域上的重构误差：

$$\min_{\theta_g} \mathcal{L}_{recon}^t = \frac{1}{N_t} \sum_{i=1}^{N_t} \|x_i^t - G(E(x_i^t; \theta_e); \theta_g)\|^2 \quad (18)$$

该训练过程采用随机梯度下降法，参数更新规则如式(19)所示：

$$\theta_g^{(k+1)} = \theta_g^{(k)} - \eta \nabla_{\theta_g} \mathcal{L}_{recon}^t \quad (19)$$

式中， η 为微调学习率。为保持稳定性并避免振荡， η 设置为远低于预训练阶段学习率的值。微调轮次也相应减少，从而以低计算成本，使解码器学会将编码器输出的通用空间特征映射为目标域的重构特征。冻结编码器与微调解码器具体步骤的伪代码如表 1 所示。

表 1 冻结编码器与微调解码器步骤

Table 1 Steps for freezing encoder and fine-tuning decoder

基于冻结编码器与微调解码器的迁移方法	
Input: 预训练编码器参数 θ_e ，解码器初始参数 $\theta_g^{(0)}$ ，目标域数据 x^t ，微调学习率 η	
Output: 微调后的解码器参数 $\theta_g^{(*)}$	
1	固定编码器参数，不参与更新
2	for 轮次=1 to T_f do
3	//前向传播
4	$z_i = E(x_i; \theta_e)$, $\hat{x}_i = G(z_i; \theta_g)$
5	//计算目标域重构损失


```

6       $\mathcal{L}_{recon} = \frac{1}{N} \sum_{i=1}^N \|x_i - \hat{x}_i\|^2$ 
7      //反向传播
8       $\nabla_{\theta_g} \mathcal{L}_{recon}$ 
9      //更新解码器参数
10      $\theta_g^{(*)} \leftarrow \theta_g - \eta \nabla_{\theta_g} \mathcal{L}_{recon}$ 
11 End for
12 返回  $\theta_g = \theta_g^{(*)}$ 

```

5 实验验证与讨论

5.1 实验设置

本文所使用的数据源自成都与北京两地乘客公交出行上下车记录的公开数据集，从中各选取 10 万条在一天内的乘客出行数据用于实验，数据标签包含上下车点经纬度、上下车时间等信息，可较好表征公交出行需求的时空分布特征。在时间范围上，样本选取时段为 6:00-22:00，覆盖早间出行、日间平峰及晚间出行等主要运营时段，在一定程度上避免因仅采用短时段样本而引入的局部偏差。在空间分布上，成都数据集的出行需求分布范围为北纬 30.50° 至 30.78°、东经 103.93° 至 104.21°，北京数据集的出行需求分布范围为北纬 39.72° 至 40.21°、东经 116.09° 至 116.66°，整体覆盖了两地公交出行较为活跃区域。两个城市出行需求分布热力图如图 2 所示。




图 2 成都与北京出行需求分布热力图

Fig. 2 Heatmap of travel demand distribution in Chengdu and Beijing

从图 2 中可以看出两个城市的出行需求均呈现出空间集聚特征，其中成都样本中较高密度区域主要分布于天府广场-春熙路商圈、双流机场及周边通道等出行活跃区域；北京样本中较高密度区域则主要集中于西单-天安门-东单一带、北京西站与北京南站周边等区域。上述热点分布与两城市公共活动中心、综合交通枢纽及主要出行走廊的空间布局基本吻合。进一步地，两个城市的数据样本规模一致，且选取自同类型日期和相同时段，从而保证了跨城市实验在数据规模和时间窗口上的可比性。

在实验参数设置中，针对地理自编码器，近邻点数 $k=16$ ；针对 DBSCAN 算法，通过 k -距离法分析样本点与其最近邻距离的统计分布，并结合多次实验验证确定 $\varepsilon=0.3$ ；针对 MiniBatch K-means 算法，由于本文的聚类研究是为了服务于以乘客出行需求为导向的公交站点规划，因此先采用肘部法在对需求数据进行分析，并依据《城市综合交通体系规划标准(GB/T51328-2018)》中公交站点服务面积的相关规定，设定聚类中心数量为 375。其他关键参数设置如下：每次迭代训练时使用的样本数量为 1024，学习率为 0.0005，核心点生成所需的最小样本数为 15。

5.2 成都数据集实验结果与分析

为验证本文设计聚类策略的有效性，选择 K-means、DK-means、Deep embedded clustering

(DEC) 算法与本文的 GeoAE-HC 算法开展对比实验，分别对成都数据集上的出行需求数据进行聚类之后获得的结果如图 3 所示。作为算法整体效果的直观体现，从图 3 中可以看出，4 种算法均能捕捉数据沿路网分布的整体趋势，即中心城区聚类结构复杂、外围相对稀疏。相比之下，K-means 算法在密度区域的聚类结果较碎片化，DK-means 算法呈现出成片分布的聚类效果，DEC 算法在中心城区与部分过渡地带存在类别交错和边界混杂现象，而 GeoAE-HC 算法在局部走廊表现出更细的粒度与更高的碎片化程度，这在一定程度上说明其对不同类别之间的局部差异更为敏感。考虑到图 3 为了呈现整体聚类效果可能导致聚类细节的缺失，因此针对图 3 中的聚类结果，选择成都双流机场区域这一热点区域作为典型场景进行局部放大，以进一步体现不同算法的聚类效果差异，如图 4 所示。




图 3 整体聚类效果对比图
Fig. 3 Comparison of overall clustering performance





图 4 双流机场区域聚类效果对比图
Fig. 4 Comparison of clustering performance in Shuangliu airport area

从图 4 所示的聚类结果可以看出，不同聚类方法对高出行需求区域的划分能力存在显著差异。K-means 将机场核心区及周边高密度点整体归入同一簇，单一聚类中心落在区域边缘或外围过渡带，难以有效覆盖航站楼、跑道周边及外围通道等多中心、分层次的实际客流集聚点。DK-means 虽能将机场高需求区域划分为两个相对独立的功能片区，但其聚类边界仍较为粗略，部分中心仍偏离局部需求峰。DEC 的结果与 DK-means 总体相近，能在高需求区域内部形成一定分化，但由于未考虑地理邻近关系，部分聚类中心落在高密度区边缘或低需求过渡区域，削弱了对核心客流集聚点的实际服务效率。相比之下，GeoAE-HC 在高出行需求区域表现出更优的空间适配能力，其聚类中心落于高密度需求区域内部或紧邻核心峰值位置，且能够将机场热点区域进一步细化为多个连贯子区域，从而实现高密度客流区域更精准、更全面的覆盖。因此，若以聚类中心作为公交站点布局依据，GeoAE-HC 相较于对比方法更能确保站点落于实际出行集聚位置，有效提升对主要客流需求热点的服务覆盖能力。

为增强聚类结果在实际公交运营场景中的可解释性，将各簇的聚类中心视为潜在的公交站点选址，引入两项运营指标以评估其服务效能：一项为 500m 需求覆盖率，用于衡量站点周边 500m 范围内所能服务的需求点比例；另一项为乘客平均步行距离，将该簇内所有需求点与站点映射至真实步行路网以统计需求点到对应站点的平均步行距离。考虑到部分低需求站点对整体指标可能产生干扰，故以各站点所覆盖的需求点数量为权重进行加权统计，从而更真实地反映在实际场景中乘客所获得的平均服务体验。在成都数据集上各算法对比结果如表 2 所示。

表 2 成都数据集各算法运营指标对比
Table 2 Comparison of algorithm operational metrics in the Chengdu dataset

算法	500m 需求平均覆盖率	乘客平均步行距离
K-means	82.29%	759.80m
DK-means	82.24%	746.05m
DEC	66.53%	1087.56m
GeoAE-HC	90.40%	613.29m

从表 2 中的实验结果来看，GeoAE-HC 算法在两项运营指标上均显著优于其他算法，其中 K-means 和 DK-means 算法的目标是最小化样本点到所属簇中心的欧氏距离，虽然这一距离并非实际路网可达距离，但与提高站点覆盖范围、缩短乘客步行距离的业务诉求具有一致性，因此能够取得较好的覆盖率和步行距离表现。DEC 虽能通过联合优化特征表示与聚类目标生成紧凑、分离清晰的簇，但特征空间可能扭曲原始地理坐标之间的距离关系，导致聚类结果在真实地理空间中失去合理性。相比之下，GeoAE-HC 结合地理信息与自编码器的性能优势，通过引入地理约束与分层聚类策略，在保持特征学习能力的同时兼顾空间覆盖的均匀性，因此能够同时实现高覆盖率和短步行距离。

为避免得出的结论对特定聚类数过度依赖,在成都数据集上进一步探究不同算法在不同聚类中心数量下的聚类质量,将聚类中心数量的变化范围设定为 300 至 450,选择轮廓系数和 Calinski-Harabasz (CH) 指数作为评价指标。对比结果如图 5 所示。




图 5 轮廓系数与 CH 指数对比图
Fig. 5 Comparison of silhouette coefficient and CH index

详细的轮廓系数和 CH 指数的对比数据统计如表 3 所示,统计数据保留三位小数。结合图 5 和表 3 中的数据,可以看出在轮廓系数和 CH 指数这两个评价指标上,GeoAE-HC 算法均表现最优,在给定的聚类中心数量变化范围内,其轮廓系数与 CH 指数的最大值、最小值和均值均优于其他 3 种算法。

表 3 成都数据集各算法轮廓系数与 CH 指数对比

算法	轮廓系数			CH 指数		
	最大值	平均值	最小值	最大值	平均值	最小值
K-means	0.455	0.438	0.411	102840.290	99372.548	93312.160
DK-means	0.528	0.508	0.484	112549.909	108386.401	100753.176
DEC	0.578	0.545	0.501	109827.231	104530.303	100187.031
GeoAE-HC	0.614	0.599	0.582	114818.512	112737.165	109782.214

具体而言,GeoAE-HC 的轮廓系数均值为 0.599,相较于 DEC 的 0.545、DK-means 的 0.508、与 K-means 的 0.438 分别提升 9.91%、17.91%、和 36.76%;GeoAE-HC 的 CH 指数均值为 112737.165,相较于 DEC 的 104530.303、DK-means 的 108386.401 与 K-means 的 100753.176 分别提升 7.85%、4.01%和 11.89%。在成都数据集上,本文确定的聚类数量为 375,因此针对聚类中心数量等于 375 时的指标进一步进行分析。在该聚类中心数量下,GeoAE-HC 算法的轮廓系数达到 0.596,较 DEC 的 0.533、DK-means 的 0.484 与 K-means 的 0.411 分别提升 11.82%、23.14%和 45.01%。在 CH 指数方面,聚类中心数量等于 375 时,GeoAE-HC 算法的 CH 指数为 112549.909,较 DEC 的 106043.720、DK-means 的 106560.799 与 K-means 的 98348.457 分别提升 6.14%、5.62%和 14.44%。以上数据对比证明了 GeoAE-HC 算法相较于对比方法在成都数据集上对出行需求进行聚类时具有更好类内紧凑性与类间分离度。

这是由于 K-means 是依据欧氏距离进行类别划分,在地理特征异质的区域中,易将空间上邻近但属性迥异的对象归入同一簇,导致簇内结构松散、簇间差异不足,因此两项指标均最低。DK-means 在其两阶段聚类中,先通过 DBSCAN 识别密度相连的区域,再对核心点执行 K-means 细分,从而在聚类过程中融入了基于密度的空间局部感知,提升了类内紧凑性与类间分离的清晰度。DEC 通过自编码器学习可捕捉数据的深层结构,但其聚类过程未考虑地理空间的局部连续性,导致部分簇在空间上可能不够紧凑,因此在 CH 指数上表现不及 DK-means。GeoAE-HC 则进一

步通过地理自编码器，从原始坐标中学习能够反映空间分布规律的深层特征表示，这些特征在潜在空间中增强了不同区域模式的可分性。在此基础上执行分层聚类，使得最终形成的簇不仅在空间分布上连续一致，在特征空间中也表现出更高的内聚性和可分性，因此在类内紧凑与类间分离的平衡上表现最优。尽管在少数聚类数下，GeoAE-HC 因生成更细粒度、结构更丰富的分区而可能增加类内方差，导致 CH 指数被局部反超，但结合其轮廓系数全程领先及所生成空间分区在结构上的合理性，依然可以说明 GeoAE-HC 具有更优的整体聚类性能。

为进一步评估 GeoAE-HC 中所设计地理自编码器对超参数的敏感性，选择近邻点数 k 这一核心超参数开展实验。实验将 k 的取值范围设定为 10 至 30，以轮廓系数和 CH 指数作为评价指标，实验结果如图 6 所示。

实验结果表明，在超参数变化范围内，轮廓系数在 0.577 至 0.596 之间波动，相对波动幅度约为 3.19%；CH 指数在 105671.847 至 112549.909 之间波动，相对波动幅度约为 6.11%，两项指标整体波动幅度均较小。其中，当 $k=16$ 时轮廓系数达到该范围内的最大值 0.596，CH 指数为 112549.909。其余取值下的聚类质量虽略有波动，但均保持较高水平，未出现明显性能退化。上述结果说明，在所设定的取值范围内本文算法对近邻点数这一超参数具有良好的鲁棒性。




图 6 近邻点数敏感性分析图

Fig. 6 Sensitivity analysis of the number of neighboring points

5.3 北京数据集实验结果与分析

在跨域迁移至北京数据集时，利用经过域对抗训练的自编码器，该模型已在成都数据集上学习到具有域不变性的空间特征表示，预测损失和域判别准确率曲线如图 7 所示。从图 7 中可以看出，在训练初期，预测损失迅速下降并稳定在较低水平，表明特征提取器能够充分保留结构信息，具备可靠表征能力。域判别准确率从较高水平逐步下降至接近 50%，说明特征中的域特异性信息得到有效抑制，判别器难以区分样本来源。模型在维持低预测损失的同时，使域判别准确率趋近随机猜测水平，表明域对抗训练在未明显牺牲重构能力的前提下，增强了特征的域不变性，从而提升了模型的跨城市泛化能力。




图 7 预测损失和域判别准确率曲线图
Fig. 7 Curves of prediction loss and domain discrimination accuracy

在北京数据集上,采用“冻结编码器-微调解码器”迁移策略,固定编码器层以保持 GeoAE-HC 已有特征提取能力,仅对解码器进行微调。继续选取 K-means、DK-means 和 DEC 作为对比方法,在北京数据集下的运营指标数据对比统计情况如表 4 所示。

表 4 北京数据集各算法运营指标对比

Table 4 Comparison of algorithm operational metrics in the Beijing dataset

算法	500m 需求平均覆盖率	乘客平均步行距离
K-means	78.54%	614.56m
DK-means	65.42%	846.08m
DEC	54.08%	1712.78m
GeoAE-HC	92.06%	561.48m

从跨域应用的角度来看,GeoAE-HC 算法展现了出色的跨域迁移能力,在两个数据集上均保持 90%以上的覆盖率。K-means 在跨域后覆盖率小幅下降至 78.54%,但仍保持 614.56m 的较短步行距离,说明基于原始坐标的聚类方法具有一定的跨域稳定性。DK-means 则出现明显性能下滑,覆盖率降至 65.42%,步行距离增至 846.08m,表明其密度自适应机制在新数据集上因密度分布差异而造成性能损失。DEC 表现最差,覆盖率仅 54.08%、步行距离长达 1712.78m,根本原因在于其依赖在源域数据上训练的自编码器提取特征空间,当应用场景跨域后,特征空间无法自适应调整,导致聚类结果严重偏离新数据的地理分布特征,暴露出缺乏跨域迁移能力的局限。

同样为避免得出的结论对特定聚类数过度依赖,在北京数据集上计算不同聚类中心数量下 4 种聚类方法的轮廓系数和 CH 指数,实验结果如图 8 所示,详细的对比数据统计如表 5 所示。




图 8 轮廓系数与 CH 指数对比图
Fig. 8 Comparison of silhouette coefficient and CH index

表 5 北京数据集各算法轮廓系数与 CH 指数对比

Table 5 Comparison of the silhouette coefficient and CH index of various algorithms in the Beijing dataset

算法	轮廓系数			CH 指数		
	最大值	平均值	最小值	最大值	平均值	最小值
K-means	0.457	0.430	0.411	97035.604	94611.983	91385.449
DK-means	0.522	0.503	0.472	103885.449	100395.645	95216.718
DEC	0.505	0.482	0.462	98982.945	95391.663	92012.913
GeoAE-HC	0.565	0.542	0.511	105472.136	102376.112	99434.985

通过对图 8 和表 5 进行分析可以看出,在迁移至北京的数据集之后,GeoAE-HC 在轮廓系数

上的表现依然最优, DK-means 次之, DEC 再次之, K-means 最低。其中 GeoAE-HC 的轮廓系数均值为 0.542, 较 DK-means 的 0.503 提升 7.75%, 较 DEC 的 0.482 提升 12.45%, 较 K-means 的 0.430 提升 26.05%; 其 CH 指数均值为 102376.112, 较 DK-means 的 100395.645 提升 1.97%, 较 DEC 的 95391.663 提升 7.32%, 较 K-means 的 94611.983 提升 8.21%。这表明在经过域对抗训练并冻结编码器的迁移设置下, GeoAE-HC 依然能够保持最优的类内紧凑与类间分离能力。迁移学习之所以能有效提升跨城市聚类性能, 关键在于域对抗训练使编码器学会了提取城市间的共性特征。在训练过程中, 编码器与域判别器相互博弈, 最终使编码器输出的特征难以区分来自成都还是北京, 从而剥离了各城市特有的局部噪声, 保留了更具普适性的空间结构信息。当这些域不变特征被用于聚类时, 同一类型的出行区域在不同城市中能够形成相似的分佈模式, 保证了聚类算法的有效性。同时, 冻结编码器、微调解码器的策略进一步提升了跨域适配效率, 冻结编码器可保持其已具备的特征提取能力, 仅微调解码器则让模型能够快速适应新城市的重构需求。当然, 该跨域迁移策略的应用也有一定前提, 即源域与目标域的数据在特征空间中需要有一定重叠, 才能通过对抗训练有效提取共性特征, 并且源域需有足够数据支撑稳定的域不变特征学习, 而目标域数据则只需少量即可完成微调。

值得注意的是, 在聚类中心数量为 380 至 395 这个区间内以及聚类中心为 435 时, DK-means 的 CH 指数会高于 GeoAE-HC。这主要是由于 CH 指数受类内方差影响显著, DK-means 较强的空间正则化可能在特定聚类数下产生更均匀的簇内分佈, 从而暂时抬高 CH 值; 而 GeoAE-HC 所形成粒度更细的分区则可能在边界过渡区域引入轻微的类内异质性。尽管如此, 结合其轮廓系数在全范围聚类中心数量上的领先表现, 可以说明 GeoAE-HC 在跨域场景中仍表现出更优的聚类鲁棒性与可靠性。

6 结论

本文通过对公交出行区域聚类方法的研究, 提出了一种融合地理自编码器、分层聚类与迁移学习的通用框架并据此设计了一种 GeoAE-HC 算法。本文得到的主要结论如下:

(1) 在成都数据集上的实验结果表明, GeoAE-HC 在轮廓系数、CH 指数以及 500m 需求平均覆盖率、乘客平均步行距离等指标上均优于对比方法, 既验证了该方法在提升聚类结果内部紧凑性与类间分离度方面的有效性, 也体现了其在实际运营场景中具有一定的适用性。

(2) 将 GeoAE-HC 应用于北京数据集后, 其各项性能指标仍优于对比方法, 证明本文设计的跨域迁移策略具有的良好泛化能力。这得益于冻结编码器、微调解码器的策略能够保留城市间的共性结构特征, 有效支撑跨域场景下的高效适配。值得一提的是, 该策略的适用前提是源域与目标域数据在特征空间中的分佈存在重叠区域, 且源域数据量充足以保证共性特征的稳定学习。

(3) 当前研究主要针对出行需求的地理空间分佈开展聚类研究, 尚未引入时间维度信息, 未刻画出行需求的时段变化特征。未来可引入时间注意力机制, 以提升对出行需求数据的解析能力。此外, 当前实验结果以簇中心作为候选站点, 后续可结合实际路网结构、站点间距与换乘衔接等现实约束, 进一步优化站点选址方案。

参考文献:

- [1] 李文权, 邓安鑫, 郑焱, 等. 基于机器学习的中型城市居民出行方式选择行为研究[J]. 交通运输系统工程与信息, 2024, 24(2): 13-23. [LI W Q, DENG A X, ZHEN Y, et al. Analysis of residents' travel mode choice in medium-sized city based on machine learning[J]. Journal of Transportation Systems Engineering and Information Technology, 2024, 24(2): 13-23.]
- [2] SHU W N, LI Y. A novel demand-responsive customized bus based on improved ant colony optimization and clustering algorithms[J]. IEEE Transactions on Intelligent Transportation Systems, 2023, 24(8): 8492-8506.

- [3] HAMANN J, HAGEN T. Revealing trip purposes in raw GPS data by applying a multi-phase clustering approach to semantic trajectories[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2025, 26(3): 3543-3556.
- [4] WANG Y T, LI J S, YUAN Y J, et al. Optimizing urban air mobility: A ground-connected approach to select optimal eVTOL takeoff and landing sites for short-distance intercity travel[J]. *IEEE Open Journal of Vehicular Technology*, 2024, 6: 216-239.
- [5] KHAN I K, DAUD H B, ZAINUDDIN N B, et al. Addressing limitations of the K-means clustering algorithm: outliers, non-spherical data, and optimal cluster selection[J]. *AIMS Mathematics*, 2024, 9(9): 25070-25097.
- [6] 姚振兴, 刘贤, 赵一飞, 等. 手机信令不均匀定位下出行端点自适应识别方法[J]. *交通运输系统工程与信息*, 2025, 25(4): 44-52. [YAO Z X, LIU X, ZHAO Y F, et al. Adaptive trip ends identification method under uneven positioning of mobile signaling [J]. *Journal of Transportation Systems Engineering and Information Technology*, 2025, 25(4): 44-52.]
- [7] SAPUTRA R, SUPRAPTO, SIHABUDIN A. Hotspot identification through pick-up and drop off analysis of ride-hailing transport service[J]. *International Journal of Advanced Computer Science and Applications*, 2023, 14(11): 837-843.
- [8] 陈君, 田朝军, 赵清梅, 等. 基于时空行为规律挖掘的公交乘客分类方法[J]. *交通运输工程学报*, 2021, 21(5): 274-285. [CHEN J, TIAN C J, ZHAO Q M, et al. Bus passenger classification method based on spatial and temporal behavior regularity mining[J]. *Journal of Traffic and Transportation Engineering*, 2021, 21(5): 274-285.]
- [9] XING Z, ZHAO W B. Block-Diagonal guided DBSCAN clustering[J]. *IEEE Transactions on Knowledge and Data Engineering*, 2024, 36(11): 5709-5722.
- [10] HOU J, GAO H J, LI X L. DSets-DBSCAN: A parameter-free clustering algorithm[J]. *IEEE Transactions on Image Processing*. 2016, 25(7): 3182-3193.
- [11] QIAO S J, HAN N, DING Z M, et al. A Multiple-motion-pattern trajectory prediction model for uncertain moving objects[J]. *Acta Automatica Sinica*, 2018, 44, 608-618.
- [12] LI C, BAIL, LIU W, et al. Urban mobility analytics: A deep spatial-temporal product neural network for traveler attributes inference[J]. *Transportation Research Part C: Emerging Technologies*, 2021, 124: 102921.
- [13] OLIVE X, BASORA L, VIRY B, et al. Deep trajectory clustering with autoencoders[C]. *ICRAT 2020, 9th International Conference for Research in Air Transportation*, 2020: 1-8.
- [14] SARONIAN S, YOUSEFIMEHR B, GHATEE M, et al. An ensemble of deep clustering models with autoencoders to mine travel patterns from smart card data[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2024, 25(12): 20960-20969.